

Entrenar redes neuronales cuánticas para hardware limitado por T1: qué hace y qué no hace el filtro de simetría qg

Vicente Humberto Monteverde
Universidad del Museo Social Argentino (UMSA), Argentina
ORCID 0000-0001-8884-4811

Borrador del 2 de octubre de 2026

Resumen

Una red neuronal cuántica (QNN) construida con compuertas que conservan el peso de Hamming mantiene sus datos en un sector de peso, así que los disparos que salieron del sector pueden descartarse en la lectura. Este es el filtro qg de la librería qang [1, 2]. Mostramos que, con igual amortiguamiento de amplitud (T1) en todos los qubits, la lectura filtrada de una red así es exactamente la lectura sin ruido, en cualquier sector de peso. La fracción de disparos conservados es $(1 - \gamma)^{kd}$ para peso k y profundidad d , y entrenar bajo T1 con el filtro da exactamente los parámetros del entrenamiento sin ruido. Luego medimos cuánto vale esto en cuatro conjuntos de clasificación pequeños. Cada resultado se reporta con el filtro y sin él, y cada predicción quedó registrada antes de su corrida, fallas incluidas. En 60 corridas por modelo, una red entrenada en simulador y ejecutada bajo T1 gana +2.5 puntos con el filtro en peso 1 (IC 95 % [0.8, 4.1]) y +16.5 puntos en peso 2 ([11.8, 21.2]), y recupera exactamente su precisión sin ruido. Una red entrenada con el ruido calibrado sin el filtro la alcanza (diferencias de 0.1 puntos), y el filtro no corrige ni el desfase ni un T1 distinto entre qubits. Estos modelos son simulables clásicamente y no se afirma ventaja cuántica. El filtro es una manera de hacer válido el entrenamiento sin ruido bajo relajación, con un costo en disparos conocido de antemano. Los modelos se publican como `qang.qml` (versión 0.6.0, `pip install qang`).

1 Introducción

Los clasificadores cuánticos variacionales se entrenan en simuladores y se ejecutan en equipos con ruido, o se entrenan directamente con el ruido del equipo. El entrenamiento consciente del ruido [3] es el remedio habitual cuando ambos difieren. La verificación de simetría [4, 5] es otro remedio: cuando el circuito ideal conserva una cantidad, se descartan los resultados que la violan. El proyecto qang expresa las lecturas de qubits en unidades qg ($qgz = \langle \sigma_z \rangle$ y sus compañeras) [1]. Construyó un testigo de media de registro y un filtro por disparo para circuitos que conservan un peso de Hamming [2]. Esta nota hace una pregunta acotada: para una QNN que conserva el peso, ¿cuánto cambia ese filtro la precisión de un clasificador en hardware limitado por T1, y cuándo deja de importar?

Respondemos con simulación exacta, un protocolo fijo y una comparación explícita. Cada lectura se toma con qang (filtrada) y sin qang (cruda), sobre los mismos parámetros entrenados o la misma inicialización. Las predicciones de cada estudio quedaron registradas en el repositorio antes de la corrida que las puso a prueba. De 27 predicciones pre-registradas en los estudios que se resumen aquí, 22 se cumplieron y 5 fallaron; las fallas se reportan junto a los aciertos.

2 Modelo y teoría

QNN que conserva el peso. En n qubits, una compuerta RBS (*reconfigurable beam splitter*) actúa sobre un par (a, b) como una rotación de Givens entre $|10\rangle$ y $|01\rangle$ y deja fijos $|00\rangle$ y $|11\rangle$, así que conserva el peso de Hamming [6]. Usamos $n = 5$ y tres capas de compuertas RBS sobre los pares $\{(0, 1), (2, 3)\}$, $\{(1, 2), (3, 4)\}$, $\{(4, 0)\}$. Eso da 15 ángulos y profundidad $d = 9$ (subcapas). La lectura es $z = \sum_i c_i qg_Z^{(i)} + b$ con c_i, b entrenables y pérdida logística.

Codificaciones. Con cuatro variables $x \in [-1, 1]^4$ sea $v = (x, 1)/\|(x, 1)\|$; la componente constante conserva $\|x\|$. El modelo E (peso 1) pone v_i en el estado base con el qubit i excitado. El modelo W (peso 2) pone $v_i v_j$ en el estado con los qubits $i < j$ excitados, normalizado. Los sectores tienen dimensión 5 y 10.

El filtro. Con qang, la lectura conserva solo los disparos cuyo peso es igual al peso de entrada k y renormaliza (`qang.sectors.filter_distribution`). Sin qang, se usan todos los disparos.

F1/F4: exactitud con T1 igual. Sea un amortiguamiento de amplitud con probabilidad γ en cada qubit después de cada subcapa. Su operador de Kraus sin salto multiplica un estado base con k excitaciones por $(1 - \gamma)^{k/2}$: el mismo factor para todos los estados del sector de peso k . Todo salto baja el peso y sale del sector. Las compuertas que conservan el peso nunca devuelven un estado rebajado. Por eso, condicionado a que el peso sea k , el estado es exactamente el sin ruido, y

$$\text{fracción conservada} = (1 - \gamma)^{kd}. \quad (1)$$

Para $\gamma = 0.08$ y $d = 9$ es 0.472 en peso 1 y 0.223 en peso 2. Si el amortiguamiento cambia entre qubits, el factor sin salto es $\prod_{q \in S} (1 - \gamma_q)^{1/2}$ sobre el conjunto excitado S , que no es uniforme, y se pierde la exactitud. El desfase conserva el peso, así que el filtro no lo ve.

F3: entrenamiento. Como la lectura filtrada bajo T1 es igual a la sin ruido para cualquier valor de los parámetros, la pérdida y todos los gradientes son idénticos. Entrenar bajo T1 con el filtro da los parámetros del entrenamiento sin ruido, con la misma inicialización.

F2: simulabilidad. En peso 1 la red es una matriz ortogonal O de 5×5 sobre v , y z es una forma cuadrática en v . En peso k el sector tiene dimensión $\binom{n}{k}$, polinomial para k fijo. Estos modelos se pueden simular clásicamente. Si versiones más grandes y de mayor peso dejarían de serlo es otra pregunta [7] que esta nota no aborda.

3 Métodos

Conjuntos de datos (binarios): iris (versicolor contra virginica), cáncer de mama, vino (clases 0 contra 1) y dígitos (3 contra 8), con 100 muestras por clase cuando hay. Cada corrida usa una partición estratificada 70/30, estandarización, PCA a cuatro componentes donde hace falta y escalado a $[-1, 1]$; una muestra de prueba vale 2–3 puntos. El entrenamiento usa Adam durante 120 épocas, con gradientes por diferencias centrales en los ángulos. Las condiciones de ruido se aplican después de cada subcapa: T1 igual con $\gamma = 0.08$; T1 desigual con γ_q de 0.04 a 0.12 (media 0.08); y T1 igual más un cambio de fase con probabilidad 0.03. La simulación es exacta. T1 y desfase mantienen la matriz densidad diagonal por bloques según el peso de Hamming, así que se propaga un bloque por peso; se verificó contra la matriz densidad completa a 10^{-12} . Protocolo: el script de cada estudio, con sus predicciones escritas en el encabezado, se registró antes de usar la semilla de su corrida reportada; el código se depuró con otra semilla y pocas épocas. Los hashes de los commits están en las notas de investigación [1].

4 Resultados

Estudios con una semilla. La QNN que conserva el peso y la norma llega a una precisión media de 0.960 sobre los cuatro conjuntos. Queda a la par de una QNN estándar de cuatro qubits que no conserva el peso (0.952), de una máquina de vectores soporte RBF (0.957) y de una red MLP pequeña (0.961). Sin la componente de norma, la misma red obtiene 0.791. Entrenada sin ruido y ejecutada bajo T1 con el filtro, conserva exactamente su precisión sin ruido. Entrenar bajo T1 con el filtro reproduce el entrenamiento sin ruido a 5×10^{-9} en los parámetros (F3). Con $\gamma = 0.08$, una QNN estándar entrenada sin ruido colapsa bajo T1 (0.771); entrenada bajo T1 se recupera (0.944).

Las predicciones que fallaron:

- la codificación arccos no mejoró la precisión;
- el gemelo cuadrático clásico no quedó a menos de 1 punto de la QNN con la regularización por defecto;
- el T1 desigual le costó al filtro 1.5 puntos en una corrida (límite: 1 punto);
- el peso 2 fue menos preciso que el peso 1 (por 3.7 puntos);
- entrenado bajo T1, el modelo de peso 2 sin filtro quedó 0.6 puntos por delante del filtrado.

Réplica en 60 corridas. Las comparaciones clave se repitieron con 5 semillas $\times$ 3 particiones $\times$ 4 conjuntos. La Tabla 1 y la Fig. 1 dan los resultados; las cinco predicciones pre-registradas de esta réplica se cumplieron.

lectura	E (peso 1)		W (peso 2)	
	con qang	sin qang	con qang	sin qang
exacta (sin ruido)	0.952		0.922	
T1, entrenada sin ruido	0.952	0.928	0.922	0.757
T1, entrenada con el ruido	0.952	0.951	0.922	0.924
T1 desigual, entrenada sin ruido	0.947	0.921	0.916	0.732
desfase, entrenada sin ruido	0.918	0.792	0.882	0.656
desfase, entrenada con el ruido	0.950		0.926	

Tabla 1: Precisión de prueba media en 60 corridas por modelo, con y sin el filtro qg.

Las diferencias pareadas (media, IC 95 % entre semillas) fueron las siguientes.

- *Ganancia del filtro, entrenada sin ruido, bajo T1:* +2.5 [0.8, 4.1] puntos (E) y +16.5 [11.8, 21.2] (W). El modelo filtrado quedó adelante o empatado en 50/60 (E) y 56/60 (W) corridas.
- *Con entrenamiento con ruido:* +0.1 [−0.6, 0.9] (E) y −0.1 [−0.8, 0.5] (W).
- *Pérdida por T1 desigual:* 0.5 [−0.2, 1.2] (E) y 0.7 [0.0, 1.3] (W). Los 1.5 puntos de la corrida anterior estaban en el extremo alto de la dispersión.
- *Desfase, entrenamiento con ruido menos sin ruido, con filtro:* +3.2 (E) y +4.5 (W), ambos IC por encima de 0.
- *Con desfase, un modelo entrenado sin ruido igual gana* +12.6 (E) y +22.6 (W) puntos con el filtro, que elimina la parte T1 del ruido combinado.
- *Peso 2 frente a peso 1:* −3.0 [−4.0, −2.0] puntos.




Figura 1: (a) Precisión de redes entrenadas sin ruido y ejecutadas con ruido, sin (vacío) y con (lleno) el filtro; los triángulos marcan la precisión sin ruido. (b) Diferencias pareadas, media e IC 95 % sobre 5 semillas.

5 Discusión

La diferencia que hace el filtro depende de cómo se entrenó la red. Entrenada en simulador y ejecutada con relajación, el filtro es decisivo. Su efecto crece con el peso, porque un estado de peso k decae k veces más rápido. Entrenada con un modelo de ruido calibrado, una red sin filtro aprende el decaimiento, y el filtro no agrega nada medible. Lo que aporta el filtro es, por lo tanto, de procedimiento y no una ganancia de precisión sobre la mejor alternativa. Con T1 igual hace exactamente válido el entrenamiento sin ruido, sin modelo de ruido ni corridas de entrenamiento con ruido, y su costo (los disparos descartados) se conoce antes de ejecutar. El T1 desigual y el desfase no se corrigen. En hardware con mucha dispersión de T1 o desfase fuerte, el filtro complementa un modelo de ruido y no lo reemplaza.

Limitaciones. Todo el ruido es simulado. Hay una arquitectura por peso, cinco qubits y conjuntos pequeños en los que una muestra de prueba vale 2–3 puntos. La codificación de peso 2 es una elección entre muchas, y no aprovechó bien el sector más grande. No se afirma ventaja cuántica: estas redes son simulables clásicamente. Una corrida en hardware con el filtro es la siguiente prueba natural.

Disponibilidad de código y datos

Modelos: `qang.qml` en `qang` 0.6.0 (`pip install qang`), solo NumPy, con `WeightQNN`, `kept_fraction` y `compare_qang`. Estudios: `examples/qnn*_qg.py` y `RESEARCH_NOTES`

§75–§80, con pruebas en `tests/`. Los cuadernos Colab `notebooks/qang_qml_es.ipynb` (español) y `qang_qml.ipynb` (inglés) instalan la librería desde PyPI. Repositorio: <https://github.com/Viny2030/qang>.

```
from qang.qml import WeightQNN
m = WeightQNN(n_qubits=5, weight=2).fit(X_train, y_train)
m.score(X_test, y_test, gamma=0.08, qang=True) # = precision sin ruido
m.score(X_test, y_test, gamma=0.08, qang=False) # lectura cruda
```

Referencias

- [1] Vicente Humberto Monteverde. The Qang (qg): A unified angular-probability unit and metric for parametric quantum circuit design. 2026. doi: 10.5281/zenodo.22832150.
- [2] Vicente Humberto Monteverde. The register-mean polar bias as a symmetry witness: error mitigation, constrained optimization and qubit characterization in qg units. *Zenodo preprint*, 2026. doi: 10.5281/zenodo.23036963.
- [3] Hanrui Wang, Jiaqi Gu, Yongshan Ding, Zirui Li, Frederic T. Chong, David Z. Pan, and Song Han. QuantumNAT: quantum noise-aware training with noise injection, quantization and normalization. In *Proceedings of the 59th ACM/IEEE Design Automation Conference (DAC)*, pages 1–6, 2022. doi: 10.1145/3489517.3530400.
- [4] Xavier Bonet-Monroig, Ramiro Sagastizabal, M. Singh, and Thomas E. O’Brien. Low-cost error mitigation by symmetry verification. *Physical Review A*, 98:062339, 2018.
- [5] Sam McArdle, Xiao Yuan, and Simon Benjamin. Error-mitigated digital quantum simulation. *Physical Review Letters*, 122:180501, 2019.
- [6] Jonas Landman, Natansh Mathur, Yun Yvonna Li, Martin Strahm, Skander Kazdagli, Anupam Prakash, and Iordanis Kerenidis. Quantum methods for neural networks and application to medical image classification. *Quantum*, 6:881, 2022. doi: 10.22331/q-2022-12-22-881.
- [7] M. Cerezo et al. Does provable absence of barren plateaus imply classical simulability? Or, why we need to rethink variational quantum computing, 2023. arXiv:2312.09121.